

Chap 1: Modèles et problèmes statistiques du cours -

Notations: données n nombres x_1, x_2, \dots, x_n

- Réalisations d'un n -échantillon: n variables aléatoires indépendantes de même loi X_1, X_2, \dots, X_n .
- la loi commune appartient à une famille de lois paramétrées par un paramètre inconnu. $\theta \in \Theta$

1.1. Modèles paramétriques

a. Bernoulli:

- sondage sur un vote à deux issues.
- qualité dans des pièces manufacturées (avec ou sans défaut).
- étude d'inondation (un fleuve va-t-il déborder?).
- un patient est-il malade ou pas?
- un enfant qui naît $\begin{matrix} \rightarrow G \\ \rightarrow F \end{matrix}$.

$n \in \mathbb{N}^*$, x_1, \dots, x_n - observations $\in \{0; 1\}$.

x_1, \dots, x_n n -échantillon $\mathcal{B}(\theta)$ $\theta \in]0; 1[$.

x_i	0	1	Total
probabilité	$1-\theta$	θ	1


$$P_\theta(X_1 = 1) = \theta$$

$$P_\theta(X_1 = 0) = 1 - \theta$$

$$E_\theta(X_1) = \theta (= 0 \times P_\theta(X_1 = 0) + 1 \times P_\theta(X_1 = 1))$$

$$V_\theta(X_1) = \theta \times (1 - \theta).$$

$$V_\theta(X_1) = E_\theta((X_1 - E_\theta(X_1))^2) = E_\theta(X_1^2) - (E_\theta(X_1))^2 = \theta - \theta^2 = \theta(1 - \theta).$$



b) Poisson.

X_1, \dots, X_n . $n \in \mathbb{B}(\theta)$, $\theta \in]0; 1[$.
 n grand θ petit

$X_1 + \dots + X_n \sim \mathcal{B}(n, \theta) \subset \{0, \dots, n\}$. Lorsque $n \rightarrow +\infty$, $\theta_n = \frac{\lambda}{n}$.

$$P_\theta(X_1 + \dots + X_n = k) = \dots$$

$$Y \sim \mathcal{P}(\lambda), P_\lambda(Y = k) = e^{-\lambda} \times \frac{\lambda^k}{k!}$$

$$\left(1 - \frac{\lambda}{n}\right)^n \rightarrow e^{-\lambda}$$

$$E_\theta(X_1 + \dots + X_n) = n \times \theta = \lambda.$$

$$\text{done } E_\lambda(Y) = \lambda.$$

$$V_\theta(X_1 + \dots + X_n) = n \times \theta(1 - \theta)$$

$$V_\lambda(Y) = \lambda.$$

$$= \lambda \times \left(1 - \frac{\lambda}{n}\right) \rightarrow \lambda$$

$m \in \mathbb{N}^*$, Y_1, \dots, Y_m : m -échantillon $\mathcal{P}(\lambda)$ de $\lambda \in \mathbb{R}_+^*$.

y_1, \dots, y_m : observations vivant dans \mathbb{N} .

$$P_\lambda(Y_1 = k) = e^{-\lambda} \times \frac{\lambda^k}{k!}, E_\lambda(Y_1) = \lambda$$


$$V_\lambda(Y_1) = \lambda.$$

c) Loi exponentielle:

Paramètre : $\lambda > 0$: loi continue à densité. Valeurs possibles : $[0; +\infty[$ ou $]0; +\infty[$.

Densité : soit $x \geq 0$.

$$f_\lambda(x) = \lambda e^{-\lambda x}$$



$$X_1, \dots, X_n \text{ 1 échantillon } \mathcal{E}(\lambda).$$

$$E_\lambda(X_1) = \int_0^{+\infty} x \times f_\lambda(x) dx = \frac{1}{\lambda} \text{ (Par l'intégration par parties)}$$


$$V_\lambda(X_1) = \frac{1}{\lambda^2}$$

②

d) Le modèle gaussien.


Modèle continu à densité.

$$X \sim \mathcal{N}(m, \sigma^2), m \in \mathbb{R}, \sigma^2 \in \mathbb{R}_+^*.$$



Densité:

$$x \in \mathbb{R}, \theta = (m, \sigma^2) : f_{\theta}(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{1}{2\sigma^2}(x-m)^2\right).$$



$$E(|X|) < +\infty.$$

$$\hat{E}_{\theta}(x) = m.$$

$$V_{\theta}(x) = \sigma^2.$$

Propriétés:

- Soit $X \sim \mathcal{N}(m, \sigma^2)$. Alors $Y = \frac{X-m}{\sigma} \sim \mathcal{N}(0, 1)$.
- Soit $Y \sim \mathcal{N}(0, 1)$. Alors, pour $\sigma > 0, m \in \mathbb{R}, X = \sigma Y + m \sim \mathcal{N}(m, \sigma^2)$.
- Soit $X \sim \mathcal{N}(m, \sigma^2)$. Soit $Y = \frac{X-m}{\sigma}$. Soit $t \in \mathbb{R}$,

$$P(Y \leq t) = P\left(\frac{X-m}{\sigma} \leq t\right) = P(X \leq t\sigma + m).$$

$$= \int_{-\infty}^{t\sigma + m} \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{1}{2\sigma^2}(x-m)^2\right) dx.$$

Posons $y = \frac{x-m}{\sigma}$. $dy = \frac{dx}{\sigma}$

$$P(Y \leq t) = \int_{-\infty}^t \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{y^2}{2}\right) dy = P(\mathcal{N}(0, 1) \leq t).$$

Soit $X \sim \mathcal{N}(m, \sigma^2)$ alors $Y = \frac{X-m}{\sigma} \sim \mathcal{N}(0, 1)$. (et vice-versa).

Proposition: Soit $Y \sim \mathcal{N}(0, 1)$.

$$E(|Y|) < +\infty$$

$$E(Y) = 0$$

$$E(Y^2) < +\infty$$

$$E(Y) = 1$$

$$E(|Y|) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{+\infty} |y| e^{-\frac{y^2}{2}} dy = \frac{2}{\sqrt{2\pi}} \int_0^{+\infty} y e^{-\frac{y^2}{2}} dy = \frac{2}{\sqrt{2\pi}} \left[-e^{-\frac{y^2}{2}} \right]_0^{+\infty} = \frac{2}{\sqrt{2\pi}} < +\infty$$

$$E(Y^2) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{+\infty} y^2 e^{-\frac{y^2}{2}} dy = \frac{2}{\sqrt{2\pi}} \int_0^{+\infty} y^2 e^{-\frac{y^2}{2}} dy$$

Integ par parties -

$$= \frac{2}{\sqrt{2\pi}} \left([uv]_0^{+\infty} - \int_0^{+\infty} u'v \right)$$

$$= \frac{2}{\sqrt{2\pi}} \left(\left[-y e^{-\frac{y^2}{2}} \right]_0^{+\infty} + \int_0^{+\infty} e^{-\frac{y^2}{2}} dy \right)$$

$$= \frac{2}{\sqrt{2\pi}} \left(0 + \int_0^{+\infty} e^{-\frac{y^2}{2}} dy \right)$$

$$= \frac{2}{\sqrt{2\pi}} \int_0^{+\infty} e^{-\frac{y^2}{2}} dy$$

$$E(Y^2) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{+\infty} e^{-\frac{y^2}{2}} dy = 1 < +\infty$$



Exercice : $E(Y^4) = 3$

$$E(Y) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{+\infty} y e^{-\frac{y^2}{2}} dy = 0.$$

$$V(Y) = E((Y - E(Y))^2) = E(Y^2) = 1.$$

Formule de répartition de Y .

$$\Phi(t) = P(Y \leq t) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^t e^{-\frac{y^2}{2}} dy.$$



$$\Phi(t) = 1 - \Phi(-t).$$

$$P(a \leq Y \leq b) = \Phi(b) - \Phi(a).$$

Exercice : mq $E(Y^4) = 3$.

$$E(Y^4) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{+\infty} y^4 e^{-\frac{y^2}{2}} dy = \frac{4}{\sqrt{2\pi}} \int_0^{+\infty} y^3 \cdot y e^{-\frac{y^2}{2}} dy.$$

Intégration par parties : $u' = y^3$, $u = y^4$, $v = y e^{-\frac{y^2}{2}}$, $v' = y e^{-\frac{y^2}{2}}$.

$$\frac{1}{\sqrt{2\pi}} \int_0^{+\infty} y^3 \cdot y e^{-\frac{y^2}{2}} dy = \frac{1}{\sqrt{2\pi}} \left(\left[y^4 e^{-\frac{y^2}{2}} \right]_0^{+\infty} + 3 \int_0^{+\infty} y^2 e^{-\frac{y^2}{2}} dy \right).$$

$$= \frac{1}{\sqrt{2\pi}} \left(3 \int_0^{+\infty} y^2 e^{-\frac{y^2}{2}} dy \right)$$

$$= \frac{1}{\sqrt{2\pi}} \left(3 \int_0^{+\infty} e^{-\frac{y^2}{2}} dy \right) \cdot (cf: E(Y^2))$$

$$= 3 < +\infty$$

③

1.2. Décision statistique, coût, risque.

X_1, \dots, X_n n-échantillon θ , x_1, \dots, x_n les n observations

Je me pose une question qui me concerne θ
 ↗ estimation ponctuelle
 ↘ estimation par intervalle de θ .
 → t est $(\theta \pm \frac{1}{2})$ ou pas ?

Je veux y répondre à partir de ce que j'observe et que je connais -

d: décision $d(x_1, \dots, x_n)$

Fonction de coût qui me quantifie chaque erreur.

Ex: Estimation

$$L(d(x_1, \dots, x_n), \theta) \geq 0$$

$$L_1(d(x_1, \dots, x_n), \theta) = |d(x_1, \dots, x_n) - \theta|$$

$$L_2(d(x_1, \dots, x_n), \theta) = (d(x_1, \dots, x_n) - \theta)^2$$

$$E_{\theta}(L(d(x_1, \dots, x_n), \theta)) = R(d, \theta) \quad \text{risque}$$

Ex: Bernoulli $B(\theta)$.

x_1, \dots, x_n $x_i \begin{cases} 1 \text{ si Face} \\ 0 \text{ si Pile} \end{cases}$

$$\frac{x_1 + \dots + x_n}{n} = \bar{x}_n = d(x_1, \dots, x_n)$$

$$R(\bar{x}_n, \theta) = E_{\theta}[(\bar{x}_n - \theta)^2]$$